

PROJEKT: Kiedy model powinien powiedzieć „nie wiem”?

Kontekst i cel projektu

Modele uczenia maszynowego często zwracają wartości wyglądające jak prawdopodobieństwa. W praktyce są to jednak zwykle jedynie miary pewności modelu (*confidence*), które nie zawsze odpowiadają rzeczywistej poprawności predykcji.

Model może być bardzo pewny swojej decyzji i jednocześnie całkowicie się mylić.

Celem projektu jest zbadanie:

czy model potrafi poprawnie oceniać własną niepewność

oraz sprawdzenie, kiedy powinien powiedzieć:

„nie wiem”.

Opis danych

Rekomendowanym zbiorem danych jest konkurs Kaggle:

[Natural Language Processing with Disaster Tweets](#)

Zadanie polega na klasyfikacji tweetów do jednej z dwóch klas:

- 1 – tweet dotyczy prawdziwej katastrofy,
- 0 – tweet nie dotyczy prawdziwej katastrofy.

W zakładce **Code** konkursu dostępne są przykładowe notebooki pokazujące sposób wczytywania danych oraz podstawowe modele bazowe.

Modele

W projekcie należy wykorzystać przynajmniej jeden sensowny model bazowy, np.:

- TF-IDF + Logistic Regression,
- MLP na embeddingach tekstu,
- LSTM/GRU,
- mały Transformer (np. DistilBERT, MiniLM).

Nie oczekujemy trenowania dużych modeli językowych od zera.

Co należy zbadać?

Projekt składa się z trzech etapów.

1. Baseline i diagnoza problemu

Wytrenujcie model i oceńcie jego skuteczność za pomocą podstawowych metryk:

- Accuracy,
- Precision / Recall / F1,
- macierzy pomyłek.

Następnie sprawdźcie:

- czy confidence modelu odpowiada rzeczywistej poprawności,
- przykłady błędnych predykcji z bardzo wysoką pewnością,
- reliability diagram,
- Expected Calibration Error (ECE).

2. Kalibracja modelu

Przetestujcie przynajmniej 2–3 metody poprawy kalibracji lub estymacji niepewności, np.:

- Temperature Scaling,
- Label Smoothing,
- Monte Carlo Dropout,
- Ensemble modeli,
- Isotonic Regression.

Porównajcie wyniki przed i po kalibracji.

3. Mechanizm „nie wiem”

Zaprojektujcie prosty mechanizm odrzucania niepewnych predykcji.

Przykładowo:

Jeśli $\text{confidence} > \tau$, model odpowiada.
Jeśli $\text{confidence} \leq \tau$, model mówi: „**nie wiem**”.

Przetestujcie kilka wartości progu τ i pokażcie kompromis między:

- accuracy,
- coverage,
- liczbą odrzuconych przykładów.

Dla ambitnych: możecie spróbować prostego conformal prediction.

Wymagane elementy prezentacji

Przygotujcie prezentację trwającą około 5–7 minut.

Powinna ona zawierać:

- krótkie wyjaśnienie różnicy między confidence a prawdopodobieństwem,
- wyniki modelu bazowego,
- przykłady błędnych, ale bardzo pewnych predykcji,
- reliability diagram,
- porównanie metod kalibracji,
- analizę mechanizmu „nie wiem”,
- najważniejsze wnioski z eksperymentów.

Ważna uwaga

W tym projekcie **accuracy nie jest najważniejszą metryką**.

Najważniejsze są:

- analiza relacji między confidence a rzeczywistą poprawnością,
- wykrywanie nadmiernej pewności modeli,
- poprawna interpretacja wyników,
- jakość eksperymentów i wyciąganych wniosków.

Materiały pomocnicze

Przydatne prace:

- *On Calibration of Modern Neural Networks* (Guo et al., 2017),
- *Calibration of Pre-trained Transformers* (Desai & Durrett, 2020),
- *A Gentle Introduction to Conformal Prediction* (Angelopoulos & Bates, 2021).